

A pergunta do trabalho: *quantas horas um navio vai operar no berço no Porto de Santos?*

Equipe Shannon

Santos-SP, 2 de outubro de 2026

Fatec Baixada Santista, Rubens Lara | Tecnologia em Ciência de Dados
Teoria do Aprendizado Estatístico | Prof. Dr. João Paulo Ferreira de Mello
Adriane da Costa Santos (RA 0051352511040) Danilo Prado de Lima Silva (RA 0051352521019)
Victória Cabral Quintério (RA 0051352521033)
Repositório: `teoriaaprendizadoestatistico`

1 Introdução

A capacidade do Porto de Santos, o maior da América Latina, depende do tempo em que cada berço fica ocupado. Este texto apresenta o banco, formula a pergunta do semestre e a defende: como propõe James et al. (2021), duas candidatas foram comparadas com uma linha de base por validação cruzada e escolhidas pelos números.

2 O banco de dados e o problema

Os dados vêm do Estatístico Aquaviário da ANTAQ (AGÊNCIA NACIONAL DE TRANSPORTES AQUAVIÁRIOS, 2025): tabelas *Atracação*, *Tempos de Atracação* e *Carga* de 2024, ligadas por `IDAtracacao`, com a carga agregada por escala (peso bruto, TEU, partidas e natureza predominante). Cada linha é uma **escala**: uma atracação para movimentação de carga no Complexo Portuário de Santos. Das 5.739 escalas com tempo de operação registrado, ficaram as que não passam do percentil 99 (172,9 h): $n = 5.681$ escalas e $p = 7$ preditores candidatos. A resposta é `T0peracao` (T3), o tempo entre o início e o término da movimentação de carga.

O banco é público, granular e da região da Fatec. O *problema* é a programação de berços: as janelas de atracação dependem de estimativas de duração, e um erro de horas se propaga para a fila seguinte.

3 A pergunta

A pergunta do trabalho é: **quando um navio é programado para atracar em Santos, quantas horas ele vai operar no berço?** A pergunta concorrente, menos ambiciosa, é se essa operação vai passar de 24 horas. A Tabela 1 detalha os sete campos de cada uma.

Quem programa o berço precisa de horas, não de um rótulo (regressão), e quer acertar navios que ainda não chegaram, não interpretar coeficientes (*predição*) (JAMES et al.,

Tabela 1 – Ficha das duas perguntas candidatas

Campo	Pergunta 1 (escolhida)	Pergunta 2
1. Pergunta	Quantas horas o navio vai operar no berço?	A operação passará de 24 h?
2. Resposta Y	T0peracao (T3), quantitativa, em horas	1 {T3 > 24}, binária
3. Preditores X	log de peso, TEU e partidas; natureza; navegação; terminal; mês ($p = 30$)	os mesmos da Pergunta 1
4. Tipo	supervisionado; regressão; predição	supervisionado; classificação; predição
5. Métrica	RMSE em horas (apoio: MAE)	AUC (apoio: acurácia)
6. Base	média do treino: RMSE = 32,8 h	classe comum: acur. 0,608; AUC 0,5
7. Dono	Autoridade Portuária e terminais: a janela	os mesmos: reservar mais de um dia?

Fonte: Elaborada pelos autores.

2021). Por isso só entra em X o que já se conhece na programação, restrição que guia a Seção 4.

4 Defesa da pergunta

Tabela 2 – Diagnóstico do banco

Verificação	Resultado
Tamanho ($n \times p$)	5.681×7 (30 com <i>dummies</i> ; ≈ 183 obs. por parâmetro)
Maior correlação com Y	dur.datas 1,000; TAtacado 0,968; depois: log.teu 0,493
Balanço (Pergunta 2)	longas 3.455 (60,8%); curtas 2.226 (39,2%)
Valores faltantes	T2 684; T4 79; T1 78; TEstadia 73; TAtacado 3 (preditores: 0)

Fonte: Elaborada pelos autores.

Vazamento. Na Tabela 2, a maior correlação é 1: **dur.datas**, diferença entre as datas de término e de início da operação, é o próprio T3. **TAtacado** soma T2, T3 e T4 e também contém a resposta. Ambas saíram, com **TEstadia**; T1, T2 e T4 também saíram, pois só são conhecidos depois da chegada do navio (vazamento temporal). Sem elas, a maior correlação cai para 0,493 (**log.teu**), relação física esperada: mais contêineres exigem mais movimentos de guindaste.

Tamanho, balanço e faltantes. Com ≈ 183 observações por parâmetro, o ajuste por mínimos quadrados é estável. As classes da Pergunta 2 ficam perto de 60/40, mas a acurácia de 0,608 sai sem modelo, o que justifica a AUC (BRUCE; BRUCE; GEDECK, 2020). Os faltantes estão só nas colunas descartadas (T2: 12,0%); não houve imputação.

A resposta é assimétrica (Figura 1; média de 41,2 h, mediana de 30,0 h), e o RMSE em horas penaliza justamente as operações longas, que mais pesam na fila.


Escolha. As duas batem as suas bases: o **lm** reduz o RMSE em 27,7% e o **glm** chega a AUC 0,915. Decide a última linha da Tabela 3: cortada em 24 h, a previsão da Pergunta

Tabela 3 – Validação cruzada ($k = 5$): média entre dobras (desvio padrão)

Pergunta	Modelo	Métrica principal	Apoio
1 (RMSE, MAE em h)	linha de base: média	32,8 (0,7)	25,4
	lm em horas	23,7 (0,6)	16,4
2 (AUC, acurácia)	linha de base: classe comum	0,500	0,608
	glm logístico	0,915 (0,009)	0,840
	lm da Pergunta 1 cortado em 24 h	0,899 (0,010)	0,809

Fonte: Elaborada pelos autores. Mesmas dobras (semente 1) em todos os modelos; base reestimada em cada dobra.

Figura 1 – Distribuição do tempo de operação T3 nas escalas de Santos em 2024



Fonte: Elaborada pelos autores.

1 dá AUC 0,899, só 0,016 abaixo. A Pergunta 1 contém a 2 a custo pequeno, e o contrário não vale, pois um rótulo não devolve horas. Por isso a Pergunta 1 foi escolhida.

Veredito. A pergunta se sustenta, e o descarte de vazamento a refinou: de *quanto tempo o navio opera* para *quanto tempo vai operar*, dado o que se sabe na programação. Ela é **provisória**: após a Aula 12, árvores e *ensembles* podem captar interações entre terminal e natureza da carga, e uma validação temporal pode revelar otimismo na validação cruzada aleatória.

Referências

AGÊNCIA NACIONAL DE TRANSPORTES AQUAVIÁRIOS. *Estatístico Aquaviário: base de dados de atracações, tempos de atracação e cargas, ano 2024*. 2025. Brasília: ANTAQ. Disponível em: <<https://web3.antaq.gov.br/ea/sense/download.html>>. Acesso em: 2 out. 2026.

BRUCE, P.; BRUCE, A.; GEDECK, P. *Practical Statistics for Data Scientists: 50+ essential concepts using R and Python*. 2. ed. Sebastopol: O'Reilly, 2020.

JAMES, G. et al. *An Introduction to Statistical Learning: with applications in R*. 2. ed. New York: Springer, 2021.