

Oficina — Da exploração à pergunta

Como transformar um banco de dados numa pergunta que se pode responder — e testar

Prof. Dr. João Paulo Ferreira de Mello

22 de setembro de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

O que vamos fazer hoje


- **De onde viemos:** sete laboratórios no banco de vocês — regressão, logística, treino/teste, validação cruzada, *bootstrap*, Lasso. Tudo isso *sem nunca ter dito o que estamos tentando descobrir*.
- **O de hoje:** dar nome a isso. Uma **pergunta** — formulada, classificada e *testada* contra os seus dados.
- **Para onde vai:** a entrega de 09/10, e depois dela todo o resto do trabalho.

Observação

Vocês **não precisam** das ferramentas que ainda faltam para escolher a pergunta. Precisam das que já têm — e elas servem exatamente para *descartar* pergunta ruim.

Que tipos de pergunta existem

Toda pergunta cabe em três decisões



E, valendo para *qualquer* um dos ramos, uma terceira decisão: eu quero **predição** (acertar Y num caso novo) ou **inferência** (entender *como* os X se relacionam com Y)? Ela não muda o modelo — muda o que você vai reportar no fim.

“Mas ainda não vimos árvores, redes, SVM...”

Não faz diferença para *escolher* a pergunta. O que falta são **modelos melhores para as mesmas perguntas**:

A pergunta	Ferramenta hoje	Ferramenta depois
“Quanto vai custar?” (regressão)	lm, Ridge, Lasso	árvores (A11), <i>ensembles</i> (A12), MLP (A14), SVM (A15)
“Vai acontecer?” (classificação)	glm logística	árvores, florestas, MLP, SVM
“Quem se parece com quem?” (não supervisionado)	—	k-médias (A16), EM (A17), PCA (A18)

Em palavras: a coluna do meio vai melhorar; a da esquerda, não muda. A árvore da Aula 11 responderá “este cliente vai inadimplir?” melhor que a logística da Aula 5 — mas é a *mesma* pergunta.

Observação

Única exceção: quem não tem Y nenhum. Se for o seu caso, escolha uma pergunta supervisionada **por ora** — quase todo banco tem alguma coluna que serve de resposta — e volte ao agrupamento no Bloco V.

Anatomia de uma pergunta

A ficha da pergunta: sete campos

Campo	Preenchido, no exemplo da imobiliária
1. A pergunta, <i>em uma frase</i> , sem jargão	“Quanto vale um imóvel que acabou de entrar na carteira?”
2. A resposta Y: coluna, tipo, unidade	preco — quantitativa contínua — mil R\$
3. Os preditores X: quais e quantos	area, quartos, idade, bairro ($p = 4$)
4. O tipo (as três decisões)	supervisionado; regressão ; predição
5. A métrica	RMSE, em mil R\$
6. A linha de base a bater	104 (o RMSE de chutar sempre a média)
7. O dono do problema	o corretor — para decidir o preço de anúncio

O campo **7** é o que separa uma pergunta de um exercício: se ninguém decidiria nada diferente com a resposta, a pergunta não vale o trabalho.

Quatro perguntas ruins — e o conserto

1. “Vamos analisar os dados de vendas.”

Não é pergunta: não tem Y , nem decisão. $\Rightarrow$ “Quanto a loja X vai vender no próximo mês?”

2. “O que **causa** a inadimplência?”

Dado observacional não entrega causa. $\Rightarrow$ “Que características estão *associadas* à inadimplência?” (inferência — e o relatório diz *associação*).

3. “Prever o preço a partir da comissão.”

A comissão é 6% do preço: o modelo já sabe a resposta. $\Rightarrow$ tirar a coluna — é **vazamento** (Aula 6).

4. “Prever se o imóvel foi vendido.”

90% já são “sim”: chutar “sim” sempre acerta 90%. $\Rightarrow$ trocar a resposta, ou manter e trocar a *métrica* (AUC, *recall*) — nunca acurácia.

Os dois últimos não se descobrem pensando: descobrem-se **olhando os dados**. É o que faremos agora.

Os seus dados respondem?

Um banco para praticar (com defeitos plantados)

```
head(imoveis, 4)
```

```
#>   preco area quartos idade bairro comissao preco_m2 vendido
#> 1   370   190      2    39  morro    22.2    1.95    sim
#> 2   459   161      4    22  praia    27.5    2.85    sim
#> 3   242    78      3    39 centro    14.5    3.10    sim
#> 4   359   107      2    33 centro    21.5    3.36    sim
```

Parece um banco de imóveis honesto. **Tem três problemas graves** — e nenhum deles se vê olhando a tabela. Vamos achá-los com quatro comandos.

Observação

Rode estes mesmos quatro comandos no *seu* banco hoje. Eles são o diagnóstico que decide se a pergunta de vocês tem chance.

Primeiro: o número que qualquer um bate sem modelo

Definição

A **linha de base** é o desempenho do palpite mais burro possível: a *média* de Y (regressão) ou a *classe mais comum* (classificação). Nenhum modelo que não a supere merece ser reportado.

```
sd(imoveis$preco)                                # RMSE de chutar a media

#> [1] 102.5

max(table(imoveis$vendido)) / nrow(imoveis)      # acuracia de chutar "sim"

#> [1] 0.9
```

Leia os números: num modelo de preço, errar 104 mil reais é o *empate*. Num modelo de “vendido”, 90% de acurácia é o empate — e note como esse segundo número é traiçoeiro: soa ótimo, e não vale nada.

Descarte 1: vazamento — o preditor que já sabe

```
num <- imoveis[sapply(imoveis, is.numeric)]           # so as colunas numericas
sort(abs(cor(num, use = "complete.obs")[, "preco"]), decreasing = TRUE)
```

```
#>   preco comissao   area preco_m2 quartos   idade
#> 1.0000  1.0000  0.8347  0.2687  0.2424  0.2230
```

comissao tem correlação **1,000** com o preço — porque é 6% dele. Olhe o estrago se ela entrar no modelo:

```
d <- na.omit(imoveis)
c(com_comissao = summary(lm(preco ~ area + quartos + idade + comissao, d))$r.squared,
  sem_comissao = summary(lm(preco ~ area + quartos + idade, d))$r.squared)
```

```
#> com_comissao sem_comissao
#>      1.0000      0.8954
```

$R^2 = 1$ e erro de treino de 0,45 mil reais. Parece o modelo perfeito; é só a resposta escondida numa coluna. **Se está bom demais, procure o vazamento** (Aula 6).

Descartes 2, 3 e 4: tamanho, balanço e buracos

```
c(n = nrow(imoveis), p = ncol(imoveis) - 1)  # 2) ha observacoes por preditor?

#>      n      p
#> 120     7

table(imoveis$vendido)                        # 3) as classes sao equilibradas?

#>
#> nao sim
#>  12 108

f <- colSums(is.na(imoveis)); f[f > 0]        # 4) quais colunas tem buraco?

#> idade
#>      9
```

- **n contra p :** 120 observações para 7 colunas é confortável. Se p chegar perto de n , releia a Aula 8 — e conte com regularização desde o começo.
- **Balanço:** 108 contra 12 — com classes assim, acurácia mente; use AUC ou *recall* da classe rara (Aula 5).
- **Faltantes:** 9 em idade. Imputar é pré-processamento: entra **dentro** do laço da validação cruzada (Aula 7).

Por que o desbalanço é o mais cruel dos quatro

Ajustamos uma logística honesta para prever vendido:

```
d$vendido <- factor(d$vendido)
g <- glm(vendido ~ area + quartos + idade, data = d, family = binomial)
pred <- ifelse(predict(g, type = "response") > 0.5, "sim", "nao")
c(acuracia_modelo = mean(pred == d$vendido),
  acuracia_chute = max(table(d$vendido)) / nrow(d),
  quantas_vezes_preuiu_nao = sum(pred == "nao"))

#>          acuracia_modelo          acuracia_chute
#>                0.8919                0.8919
#> quantas_vezes_preuiu_nao
#>                0.0000
```

Leia a saída: o modelo tem 89,2% de acurácia — exatamente a mesma do chute. E previu “não” em **zero** dos 111 casos. Ele não aprendeu nada: aprendeu a dizer “sim” sempre, e a métrica o elogiou por isso.

Observação

É por isso que a *linha de base* vem antes do modelo, e não depois. Sem ela, esse 89% iria para o relatório como sucesso.

A entrega e o laboratório de hoje

A entrega de 09/10: duas perguntas, uma escolhida

Em consolidados/, um .md de no máximo **duas páginas**, mais o código em estrutura/codigo/:

1. **Duas perguntas candidatas**, cada uma com a *ficha de sete campos*. A segunda pode ser mais curta.
2. Para cada uma: a **linha de base** e um $\ell_m/g\ell_m$ avaliado por **validação cruzada de 5 dobras**, na métrica da ficha.
3. O **diagnóstico do banco**: os quatro comandos de hoje, com o que vocês encontraram e o que fizeram a respeito.
4. A **escolha**, justificada *com os números* — não com gosto pessoal.
5. Uma linha: “*o que as próximas aulas podem mudar nesta resposta*”.

Observação

A pergunta é **provisória**. Ela volta para revisão depois da Aula 12, quando vocês tiverem o kit supervisionado completo. Escolher agora não é escolher para sempre.

Agora, em grupo — o resto da aula

1. **(10 min)** Abram os seus consolidados/ das Aulas 4 a 8. *Que resposta Y vocês já usaram sem perceber?*
A pergunta costuma estar lá.
2. **(10 min)** Rodem o diagnóstico no banco de vocês:

```
num <- dados[sapply(dados, is.numeric)]  
sort(abs(cor(num, use = "complete.obs")[, "y"]), decreasing = TRUE) # vazamento?  
c(n = nrow(dados), p = ncol(dados) - 1) # tamanho?  
table(dados$y) # balanço?  
colSums(is.na(dados)) # buracos?
```

3. **(20 min)** Escrevam as *duas* fichas. Em voz alta, no grupo: “quem decidiria o quê com essa resposta?”
4. **(10 min)** Me chamem. Passo em cada grupo para ouvir as duas perguntas antes de vocês investirem a semana nelas.

- Toda pergunta cabe em **três decisões**: tem Y ? Y é quantitativa? quero prever ou entender?
- As ferramentas que faltam dão **respostas melhores**, não perguntas novas.
- A **ficha de sete campos** força a clareza — e o campo do *dono do problema* é o que mais elimina pergunta vazia.
- **Linha de base primeiro**. Depois os quatro descartes: vazamento, n contra p , balanço, faltantes.

Entrega: 09/10, em consolidados/. **Revisão da pergunta:** depois da Aula 12.