

# Aula 1 — Introdução ao Aprendizado Estatístico

Estimar  $f$ ; predição e inferência; paramétrico e não-paramétrico;  
supervisionado e não-supervisionado

---

Prof. Dr. João Paulo Ferreira de Mello

4 de agosto de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

# Apresentação da disciplina

**Professor:** João Paulo F. de Mello

**E-mail:** joao.mello12@fatec.sp.gov.br

**Ementa (fio condutor):** estimar e avaliar modelos de aprendizado a partir de dados — da regressão às redes neurais e ao aprendizado não supervisionado — sempre com **pseudocódigo** e **implementação em R**.

## Os cinco blocos do curso:

- I. Fundamentos do aprendizado estatístico
- II. Supervisionado: avaliação e regularização
- III. Modelos flexíveis: suavização, árvores, ensembles
- IV. Redes neurais e SVM
- V. Não supervisionado: agrupamento, EM, PCA/ICA

## Provas

- **P1:** 29/09 (Blocos I–II)
- **P2:** 13/11 (Blocos III–IV)
- **P3 (substitutiva):** 11/12

## Reposições (sábados)

- 29/08, 19/09, 31/10, 28/11

## Datas fixas

- Início: 03/08 Término: 14/12
- Aulas: terças e sextas, 1h40
- Sem aula (feriado): 08/09 e 20/11
- Exames finais: 17–23/12

## Observação

As datas de prova ainda podem ser ajustadas; confirmo na semana anterior a cada avaliação.

**Normas.** Chamada no início da aula (falta reprova); sem celular, salvo quando solicitado; questionamentos de nota em até 7 dias; não há entregas fora do prazo; acompanhe e-mail e Teams diariamente.

**Estudo.** Releia as notas de aula e resolva as listas ao longo da semana — o laboratório em R é parte da avaliação.

## **Bibliografia.**

- James, Witten, Hastie, Tibshirani. *An Introduction to Statistical Learning*. (ISL)
- Bruce & Bruce & Gedeck. *Practical Statistics for Data Scientists*. (PSDS)
- Hastie, Tibshirani, Friedman. *The Elements of Statistical Learning*. (ESL)

# O que vamos ver hoje

- **Ponto de partida:** temos dados; queremos aprender com eles.
- **Os conceitos novos:** a função  $f$  em  $Y = f(X) + \varepsilon$ ; *predição vs inferência*; métodos *paramétricos vs não-paramétricos*; o compromisso *viés-variância*.
- **Para onde leva:** este vocabulário sustenta *todo* o curso — cada modelo que veremos é uma forma de estimar  $f$ .

Hoje montamos o *mapa*. As próximas aulas preenchem cada região dele.

## **O que é aprendizado estatístico**


---

# Por que isto importa

Suponha que registramos a **verba de publicidade** e as **vendas** de um produto em vários mercados. Existe uma relação — e gostaríamos de usá-la para *prever* vendas e para *entender* o que as move.

## Observação

A reta é só a nossa *estimativa* da relação; os pontos não caem exatamente sobre ela.



# A relação entre preditores e resposta

Sejam  $X = (X_1, \dots, X_p)$  os **preditores** e  $Y$  a **resposta**. Supomos que exista uma relação

$$Y = f(X) + \varepsilon,$$

com  $f$  uma função *desconhecida* e  $\varepsilon$  um **erro aleatório** independente de  $X$ , com  $\mathbb{E}[\varepsilon] = 0$ .

## Definição

$f$  é a **informação sistemática** que  $X$  fornece sobre  $Y$ . **Aprendizado estatístico** é o conjunto de métodos para *estimar*  $f$ .

## Observação

Notação do curso:  $n$  observações,  $p$  preditores; a estimativa de  $f$  é  $\hat{f}$  e a predição é  $\hat{Y} = \hat{f}(X)$ .



## Exemplo

Renda em função dos *anos de estudo*. A parte sistemática — pessoas com mais estudo tendem a ganhar mais — é  $f$ . O desvio de cada pessoa em torno dessa tendência (sorte, setor, cidade) é o erro  $\varepsilon$ .

Estimar  $f$  serve a dois propósitos, que orientam *todo* o curso:

- **Predição:** dado um novo  $X$ , quanto vale  $Y$ ?
- **Inferência:** como  $X$  e  $Y$  se relacionam?

# Duas razões para estimar $f$

## Predição

- Interessa  $\hat{Y}$  próximo de  $Y$ .
- $\hat{f}$  pode ser uma *caixa-preta*.
- Foco no desempenho *fora da amostra*.

## Inferência

- Interessa a *forma* de  $f$ .
- Quais preditores importam? Como?
- Foco em explicar e interpretar.

## Observação

O mesmo dado pode servir aos dois objetivos — mas eles pedem métodos e critérios de avaliação diferentes.

## Predição e inferência

---

## Predição: erro redutível e irreduzível

Com  $\hat{Y} = \hat{f}(X)$  e  $X$  fixo, a qualidade da predição decompõe-se em:

$$\mathbb{E}[(Y - \hat{Y})^2] = \underbrace{\left[f(X) - \hat{f}(X)\right]^2}_{\text{redutível}} + \underbrace{\text{Var}(\varepsilon)}_{\text{irreduzível}} .$$

- **Redutível:** melhora com um  $\hat{f}$  melhor — é o que os métodos do curso atacam.
- **Irreduzível:**  $\text{Var}(\varepsilon)$  é um teto; nenhum modelo o ultrapassa, pois  $\varepsilon$  não depende de  $X$ .

### Observação

Este limite justifica por que “erro zero no treino” é suspeito, e não motivo de comemoração.

Agora  $\hat{f}$  não pode ser caixa-preta: queremos sua forma. As perguntas típicas:

- Quais preditores estão **associados** à resposta?
- A relação é **positiva ou negativa**? **Linear** ou mais complexa?
- Qual o **efeito** de cada preditor, mantidos os demais?

## Exemplo

Em marketing: não basta prever vendas; quer-se saber *quanto* cada real em TV, rádio ou jornal contribui — para decidir onde investir.

# Qual objetivo em cada problema?

## Predição em primeiro lugar

Prever, do exame de sangue de um paciente, o *risco* de reação adversa a um medicamento. Importa acertar o risco; a fórmula interna é secundária.

## Inferência em primeiro lugar

Estimar o *efeito* de um ano a mais de estudo sobre o salário, controlando a experiência. Importa o coeficiente, não só a previsão.

## Observação

Definir o objetivo *antes* de escolher o método é a primeira decisão de todo projeto de Ciência de Dados.

**Como estimamos a função  $f$**

---

Reduzem a estimação de  $f$  à de *alguns parâmetros*, em dois passos:

1. **Supor a forma** de  $f$ . Ex. (linear):  $f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$ .
2. **Ajustar** o modelo aos dados, estimando  $\beta = (\beta_0, \dots, \beta_p)$ .

## Exemplo

A reta do slide de vendas é paramétrica: bastou estimar  $\beta_0$  e  $\beta_1$ .

## Observação

Simple e interpretável, mas se a forma suposta estiver longe da verdadeira  $f$ , o ajuste é ruim por construção.



Não supõem uma forma explícita para  $f$ : deixam os *dados* moldarem a curva, buscando algo próximo dos pontos sem oscilar demais.


- Mais **flexíveis** — ajustam-se a mais formas de  $f$ .
- Custam mais **dados** e são menos interpretáveis.

## Observação

Exemplos que veremos: KNN, *splines*, *loess* (Bloco III). “Sem supor a forma” não é “sem hipóteses”: ainda escolhemos suavidade e vizinhança.

# Flexibilidade × interpretabilidade

Mais flexibilidade raramente vem de graça: costuma *custar* interpretabilidade. A escolha depende do objetivo (predição ou inferência).




# O compromisso viés-variância

Aumentar a flexibilidade *reduz o viés* mas *aumenta a variância*. O erro de teste é uma curva em **U**: existe um ponto ótimo, nem rígido nem exagerado.

## Observação

Retomamos isto com rigor na **Aula 6** (avaliação e seleção de modelos).



## **Tipos de aprendizaje**

---


# Supervisionado × não-supervisionado

**Supervisionado:** há resposta  $Y$  rotulada; aprende-se a prever/ classificar (Blocos II–IV).

**Não-supervisionado:** *não* há  $Y$ ; busca-se estrutura — grupos, direções de maior variância (Bloco V).

## Observação

Ao lado, sem rótulos, o algoritmo *descobre* dois grupos (\* = centros).



Dentro do aprendizado supervisionado, o *tipo da resposta* decide o problema:

- **Regressão:** resposta *quantitativa* (renda, vendas, temperatura).
- **Classificação:** resposta *qualitativa* (inadimplente ou não; dígito 0–9).

### Observação

Os preditores podem ser de qualquer tipo nos dois casos — o que classifica o problema é a *resposta*.

# Exercícios

---

## Exercício

Num ponto  $x_0$ , um modelo tem  $f(x_0) - \hat{f}(x_0) = 0,4$  e  $\text{Var}(\varepsilon) = 0,25$ . Calcule o erro quadrático esperado  $\mathbb{E}[(Y - \hat{Y})^2]$  e diga qual parcela é irreduzível.

## Exercício

Classifique cada situação em *regressão/classificação* e *supervisionado/não-supervisionado*:

- |                                             |                                      |
|---------------------------------------------|--------------------------------------|
| a) prever o preço de um imóvel;             | c) decidir se um e-mail é spam;      |
| b) separar clientes em perfis, sem rótulos; | d) estimar a nota final de um aluno. |



## Exercício (Decomposição do erro)

Com  $Y = f(X) + \varepsilon$ ,  $\mathbb{E}[\varepsilon] = 0$  e  $\varepsilon$  independente de  $X$ , mostre que, para  $X$  fixo e  $\hat{f}$  dado,  $\mathbb{E}[(Y - \hat{f}(X))^2] = [f(X) - \hat{f}(X)]^2 + \text{Var}(\varepsilon)$ .

## Exercício (Flexibilidade)

Explique por que um método muito flexível pode ter *erro de treino* baixo e *erro de teste* alto. Relacione com viés e variância.


## Exercício (Objetivo)

Dê um problema em que a *inferência* importa mais que a predição, e outro em que ocorre o contrário. Justifique.

# Laboratório em R

Polinômios de grau 1, 4 e 15 em dados de  $f(x) = \sin(2\pi x)$ : grau 1 *subajusta*; grau 15 *sobreajusta*. **Tarefa:** ache o grau que minimiza o erro de teste.

```
x <- sort(runif(30)); y <- sin(2*pi*x) + rnorm(30, 0, .3)
xx <- seq(0, 1, len = 200); cores <- c(cverde, claranja, croxo)
plot(x, y, pch = 19, col = azul, xlab = "x", ylab = "y")
for (k in 1:3)
  lines(xx, predict(lm(y ~ poly(x, c(1, 4, 15)[k])),
    data.frame(x = xx)), col = cores[k], lwd = 2)
legend("top", c("grau 1", "grau 4", "grau 15"), col = cores,
  lwd = 2, horiz = TRUE, bty = "n", cex = 0.9)
```



- Aprender é **estimar**  $f$  em  $Y = f(X) + \varepsilon$ .
- O erro tem parte **reduzível** (atacável) e **irreduzível** (teto).
- **Paramétrico vs não-paramétrico** troca interpretabilidade por flexibilidade.
- Mais flexibilidade  $\Rightarrow$  menos viés, mais variância: o **U** do erro de teste.

**Próxima aula:** para estimar e avaliar  $f$  precisamos da língua dos dados — *estatística e probabilidade* (revisão, Aula 2).