

Aula 5 — Classificação e regressão logística

Versão expandida, com exemplos — da reta ao logístico; odds; verossimilhança; matriz de confusão; ROC

Prof. Dr. João Paulo Ferreira de Mello

27 de agosto de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

O que vamos ver hoje

- **De onde viemos:** a regressão linear (Aula 4) prevê uma resposta *quantitativa* — um número, como vendas ou renda.
- **O novo:** quando a resposta é *qualitativa* (paga/não paga, spam/não spam), o problema vira **classificação**. O modelo base é a **regressão logística**, que prevê uma *probabilidade*.
- **Para onde vai:** avaliar classificadores (matriz de confusão, ROC) prepara a avaliação de modelos da Aula 6.

O fio da aula inteira é **um único exemplo**: decidir se um banco concede crédito a um cliente, a partir do *score* dele.

Da reta ao logístico

O problema desta aula: conceder crédito?

Um banco tem o histórico de clientes: o **score** (20 a 100) e se o cliente **pagou** ($Y = 1$) ou **não pagou** ($Y = 0$) o empréstimo.

cliente	score	pagou (Y)
1	85	1
2	42	0
3	71	1
4	55	0
5	63	1

Chega um cliente novo com score 75. **Pergunta da aula:** qual a probabilidade de ele pagar — e devemos conceder o crédito?

Observação

Note a diferença para a Aula 4: não queremos prever um *número*, e sim a *probabilidade de um evento*.

Relembrando a Aula 4: quem são β_0 e β_1

Na reta $Y = \beta_0 + \beta_1 X + \varepsilon$, os coeficientes têm leitura geométrica e estatística:

- β_0 (**intercepto**): *translada* a reta para cima ou para baixo — é onde ela corta o eixo vertical. Estatisticamente: o valor médio de Y quando $X = 0$.
- β_1 (**inclinação**): *inclina* a reta. Estatisticamente: quanto Y varia, em média, a cada $+1$ em X .

Observação

Guarde essa leitura: na logística os mesmos β_0, β_1 continuam lá — a novidade será a *escala* em que eles agem (o *logit*, adiante).


Primeira tentativa: usar a reta da Aula 4

Podemos tentar $Y \approx \beta_0 + \beta_1 \text{score}$ (linha verde). Dá errado por dois motivos:

- para score baixo/alto, a reta prevê probabilidade **negativa** ou **maior que 1** — sem sentido;
- os dados em 0/1 não seguem reta: seguem um **S**.

A curva laranja (**logística**) respeita os limites: fica sempre entre 0 e 1.

```
par(mar = c(4,4,1,1), pty = "s") # quadrado
plot(score, y, pch = 19, col = "blue",
      xlab = "score", ylab = "P(pagar)")
abline(lm(y ~ score), col = "green", lwd = 2, lty = 2)
s <- seq(20, 100, length = 200)
lines(s, predict(m, data.frame(score = s),
                    type = "response"), col = "orange", lwd = 3)
abline(h = c(0, 1), col = "gray", lty = 3)
```



A estratégia: modelar p , não Y

Y só assume 0 ou 1 — não faz sentido ajustar uma função “em cima” desses dois valores. O plano da logística tem três passos:

1. **Trocar o alvo:** em vez de prever Y , modelar $p(X) = P(Y = 1 | X)$ — a probabilidade de pagar, dado o score.
2. **Reaproveitar a Aula 4:** manter a parte linear $z = \beta_0 + \beta_1 X$ como um *score de propensão*: um número livre, em $(-\infty, \infty)$; quanto maior z , mais propenso o cliente.
3. **Traduzir z em probabilidade:** z pode dar -7 ou $+13$, mas p tem de ficar em $(0, 1)$ — falta uma função que “esmague” a reta para dentro desse intervalo. É a *logística*, no próximo slide.

Observação

O 0/1 de Y não some: ele volta *no fim*, quando um **limiar** transforma p em decisão. O modelo em si nunca prevê 0/1 diretamente.

Definição

$$p(X) = P(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}.$$

Em palavras: calcule a parte linear $z = \beta_0 + \beta_1 X$ (como na Aula 4) e depois *esmague* z para dentro de $(0, 1)$ com a função $1/(1 + e^{-z})$.

Exemplo

No nosso banco, $\beta_0 = -3$ e $\beta_1 = 0,05$. Para o cliente de score 60:

$$z = -3 + 0,05 \cdot 60 = 0 \quad \Rightarrow \quad p = \frac{1}{1 + e^0} = \frac{1}{2} = 0,5.$$

$z = 0$ deu exatamente $p = 0,5$ — “cara ou coroa”. Esse ponto é tão importante que ganha o próximo slide.

O ponto de virada (fronteira de decisão)


Em que score a curva cruza $p = 0,5$? Onde a parte linear **zera**:

$$\beta_0 + \beta_1 x = 0 \implies x^* = -\beta_0/\beta_1 = 3/0,05 = 60.$$

- score < 60: $z < 0$ e $p < 0,5$ — mais provável *não* pagar;
- score > 60: $z > 0$ e $p > 0,5$ — mais provável pagar.

x^* é a **fronteira de decisão** — ideia que volta até o SVM.

```
par(mar = c(4,4,1,1), pty = "s")
curve(1/(1 + exp(-(-3 + 0.05 * x))), 20, 100,
      lwd = 3, col = claranja, xlab = "score", ylab = "p")
segments(c(60, 20), c(0, 0.5), c(60, 60), c(0.5, 0.5), lty = 2)
points(60, 0.5, pch = 19, cex = 1.4, col = croxo)
text(35, 0.75, "score < 60\np < 0.5")
text(85, 0.30, "score > 60\np > 0.5")
```




Lendo a curva em S

A mesma conta para três clientes (com $\beta_0 = -3$, $\beta_1 = 0,05$):

score	$z = -3 + 0,05s$	p
40	-1	0,27
60	0	0,50
80	+1	0,73

A curva é *quase reta* no meio e *achatada* nas pontas:
55 $\rightarrow$ 60 muda muito a probabilidade; 95 $\rightarrow$ 100, quase nada.

```
par(mar = c(4,4,1,1), pty = "s")
curve(1/(1 + exp(-(-3 + 0.05 * x))), 20, 100,
      lwd = 3, col = claranja,
      xlab = "score", ylab = "p")
pts <- c(40, 60, 80)
pp <- 1/(1 + exp(-(-3 + 0.05 * pts)))
points(pts, pp, pch = 19, cex = 1.3, col = croxo)
```



Odds, logit e estimação

O que são *chances* (odds)

Definição

As **chances** de um evento são $\frac{p}{1-p}$: a probabilidade de acontecer dividida pela de *não* acontecer.

Em palavras: é a linguagem das apostas. “Chances de 4 para 1” quer dizer: a cada 5 casos, 4 dão certo e 1 dá errado.

Exemplo

$$p = 0,8 \Rightarrow \text{odds} = \frac{0,8}{0,2} = 4 \text{ (“4 para 1”).}$$

p	0,2	0,5	0,8	0,9
odds	0,25	1	4	9

$p = 0,5$ equivale a $\text{odds} = 1$ (“1 para 1”); p perto de 1 faz as odds explodirem.

Por que aplicar o log nas chances?

Não é um truque arbitrário: o log é o **caminho de volta** até a reta. Partindo da logística $p = \frac{1}{1 + e^{-z}}$, com $z = \beta_0 + \beta_1 X$:

$$1 - p = \frac{e^{-z}}{1 + e^{-z}} \implies \underbrace{\frac{p}{1 - p}}_{\text{chances}} = \frac{1}{e^{-z}} = e^z \implies \log \frac{p}{1 - p} = z = \beta_0 + \beta_1 X.$$

Em palavras: ao formar as chances, a parte linear aparece *exponenciada* (e^z). O log é a operação que *desfaz* essa exponencial — e recupera a reta que sabemos interpretar desde a Aula 4.

Observação

Escalas: p vive em $(0, 1)$; as chances em $(0, \infty)$; o log das chances em $(-\infty, \infty)$ — exatamente onde uma reta pode viver sem estourar limites.

O logit: onde a linearidade mora

A conta do slide anterior dá nome a uma escala — o **logit**:

$$\underbrace{\log \frac{p}{1-p}}_{\text{logit}(p)} = \beta_0 + \beta_1 X \quad \Longleftrightarrow \quad \frac{p}{1-p} = e^{\beta_0} (e^{\beta_1})^X.$$

Consequência (a interpretação que importa): na forma da direita, cada +1 em X multiplica as chances por *mais um fator* e^{β_1} — a *razão de chances*.

Exemplo

No nosso modelo, $\beta_1 = 0,05$: cada ponto de score multiplica as chances por $e^{0,05} \approx 1,05$ (+5%). Em +10 pontos: $e^{0,5} \approx 1,65$ (+65% nas chances).

Observação

β_1 negativo funciona igual: $e^{\beta_1} < 1$ *reduz* as chances (ex.: $\beta_1 = -0,7 \Rightarrow$ chances caem pela metade).

A conta completa, três vezes

Vale fazer a cadeia inteira — $z \rightarrow \text{odds} \rightarrow p$ — para os três clientes:

score	$z = \text{logit}(p)$	$\text{odds} = e^z$	$p = \frac{\text{odds}}{1 + \text{odds}}$	leitura
40	-1	0,37	0,27	0,37 pra 1 <i>contra</i>
60	0	1,00	0,50	empate
80	+1	2,72	0,73	2,7 pra 1 <i>a favor</i>

Em palavras: o logit anda em passos *somados* (-1, 0, +1); as odds andam em passos *multiplicados* ($\times e$ a cada passo); e o p é só a tradução das odds de volta para probabilidade.

Observação

As três colunas contam a *mesma* informação em escalas diferentes — escolha a escala pela pergunta: interpretar (e^β), decidir (p).

Como o R estima os β : verossimilhança

Não há mínimos quadrados aqui. A ideia: escolher os β que tornam os dados observados **os mais prováveis possível**:

$$L(\beta) = \prod_{i=1}^n p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}.$$

Em palavras: para quem pagou ($y_i = 1$), entra $p(x_i)$ no produto; para quem não pagou, entra $1 - p(x_i)$. Modelo bom dá p alto para quem pagou e baixo para quem não pagou — produto grande.

Exemplo

Três clientes com $y = (1, 1, 0)$. Candidato A prevê $p = (0,9; 0,8; 0,2)$:

$L_A = 0,9 \cdot 0,8 \cdot (1 - 0,2) = 0,576$. Candidato B prevê $p = (0,6; 0,5; 0,5)$:

$L_B = 0,6 \cdot 0,5 \cdot 0,5 = 0,15$. **A explica melhor os dados** ($L_A > L_B$) — é nessa direção que o ajuste caminha.

O ajuste no R: glm()

family = binomial é o que diz “regressão logística”:

```
m <- glm(y ~ score, family = binomial)
round(coef(m), 3)           # b0 e b1, na escala do LOGIT

#> (Intercept)      score
#>      -3.769      0.057

round(exp(coef(m)["score"]), 3)  # razao de chances por +1

#> score
#> 1.058
```

Lendo a saída: os coeficientes vieram perto dos verdadeiros da simulação (-3 e $0,05$) — e $e^{\hat{\beta}_1} \approx 1,05$ confirma: cada ponto de score aumenta as chances de pagar em $\approx 5\%$.

Observação

Os coeficientes do glm estão na escala do *logit*; use `exp(coef(m))` para falar em *chances*.

De volta ao cliente de score 75

Na mão (com os β verdadeiros): $z = -3 + 0,05 \cdot 75 = 0,75$, e

$$p = \frac{1}{1 + e^{-0,75}} \approx 0,68.$$

No R (com os $\hat{\beta}$ estimados):

```
predict(m, data.frame(score = 75)) # logit
```

```
#>      1
```

```
#> 0.4924
```

```
predict(m, data.frame(score = 75), type = "response") # p
```

```
#>      1
```

```
#> 0.6207
```

Observação

Sem `type = "response"`, o `predict` devolve o *logit* (aqui $\approx 0,75$); com ele, devolve a *probabilidade* ($\approx 0,68$). É o erro mais comum da aula.

Avaliando um classificador

Da probabilidade à decisão: o limiar

O modelo dá $p = 0,68$ para o cliente. E agora — concede ou não? É preciso um **limiar** c :

$$\hat{y} = \begin{cases} 1 \text{ (concede)}, & p > c \\ 0 \text{ (nega)}, & p \leq c. \end{cases}$$

Exemplo

Com $c = 0,5$: $0,68 > 0,5 \Rightarrow$ **concede**. Com um banco conservador, $c = 0,8$: $0,68 \leq 0,8 \Rightarrow$ **nega**. O *mesmo modelo* toma decisões diferentes conforme o limiar.

Observação

O limiar não é estatística, é **decisão de negócio**: depende do custo de errar para cada lado. Isso motiva as métricas a seguir.

Matriz de confusão: um exemplo completo

Aplicamos o modelo (limiar 0,5) a 200 clientes com resultado conhecido:

	Prev. paga	Prev. não paga	total
Pagou (1)	VP = 40	FN = 20	60
Não pagou (0)	FP = 10	VN = 130	140

Acurácia = $\frac{40+130}{200} = 0,85$ — acertos no total.

Precisão = $\frac{40}{40+10} = 0,80$ — dos que previ “paga”, quantos pagaram.

Recall = $\frac{40}{40+20} \approx 0,67$ — dos que pagaram, quantos eu achei.

Especificidade = $\frac{130}{140} \approx 0,93$.

Em palavras: o modelo erra pouco ao *apontar* bons pagadores (precisão 0,80), mas *deixa escapar* 1 em cada 3 deles (recall 0,67) — clientes bons que teriam o crédito negado.

A matriz de confusão no R

`table()` cruza o real com o previsto:

```
p      <- predict(m, type = "response")
yhat <- as.integer(p > 0.5)           # limiar 0.5
table(real = y, previsto = yhat)

#>      previsto
#> real    0    1
#>    0 139   36
#>    1  41   84

mean(yhat == y)                       # acuracia

#> [1] 0.7433
```

Observação

Linhas = o que *aconteceu*; colunas = o que o modelo *disse*. Os acertos moram na diagonal. Troque 0.5 e veja a tabela mudar — é o limiar em ação.

A ideia da curva ROC

Cada limiar c produz uma matriz de confusão diferente — e, portanto, um par (FPR, TPR):

$$\text{TPR} = \text{recall} = \frac{VP}{VP + FN}, \quad \text{FPR} = \frac{FP}{FP + VN}.$$


limiar	o que acontece	onde cai
$c = 0,9$	quase ninguém vira 1	$\text{FPR} \approx 0$, TPR baixo (canto inf. esq.)
$c = 0,5$	equilíbrio	meio da curva
$c = 0,1$	quase todos viram 1	FPR e TPR ≈ 1 (canto sup. dir.)

A **curva ROC** liga todos esses pares, varrendo c de 1 a 0. A **AUC** (área sob a curva) resume: 0,5 = chute aleatório; 1 = separação perfeita.

A ROC no R

Os três pontos roxos são os limiares 0,7, 0,5 e 0,3 da tabela anterior — a curva inteira é só isso repetido para todo limiar.

```
ord <- order(p, decreasing = TRUE)
tpr <- cumsum(y[ord]) / sum(y)
fpr <- cumsum(1 - y[ord]) / sum(1 - y)
par(mar = c(4,4,1,1), pty = "s")
plot(c(0, fpr), c(0, tpr), type = "l", lwd = 3,
     col = claranja, xlab = "FPR", ylab = "TPR")
abline(0, 1, lty = 2, col = "gray")
for (L in c(0.7, 0.5, 0.3))
  points(mean(p[y == 0] > L), mean(p[y == 1] > L),
        pch = 19, cex = 1.2, col = croxo)
mean(outer(p[y == 1], p[y == 0], ">")) # AUC
```



```
#> [1] 0.81
```


Dois cuidados (com números)

1. Acurácia engana com classes desbalanceadas. Numa carteira com 1000 clientes e só 20 maus pagadores (2%), o modelo preguiçoso “todo mundo paga” acerta 980 vezes: $\text{acurácia} = 98\%$ — e **recall** = 0 para detectar maus pagadores. Acurácia alta, modelo inútil.

2. O limiar segue o custo do erro. Se conceder crédito a um mau pagador custa R\$ 5 000 e negar a um bom pagador custa R\$ 500 de lucro perdido, os erros *não* pesam igual: vale subir o limiar (ser conservador), mesmo perdendo recall.

Observação

Por isso a ROC/AUC importa: ela avalia o modelo *em todos os limiares de uma vez*, antes de a decisão de negócio escolher um.

Exercícios e trabalho

Exercício

Um modelo dá $p = 0,8$ para um cliente. Calcule as **chances** e leia o resultado em “x para 1”.

Exercício

Com $\text{logit}(p) = -1 + 0,5x$: para $x = 2$, calcule o logit, as odds e o p (as três colunas do slide “a conta completa”). Depois calcule o **ponto de virada** $x^* = -\beta_0/\beta_1$. O que você percebe?

Exercício

De uma matriz de confusão: $VP = 50$, $FP = 5$, $FN = 25$, $VN = 120$. Calcule acurácia, precisão e recall, e escreva *uma frase* interpretando o recall.

Exercício (Por que não a reta?)

Explique, com o exemplo do score, os dois motivos de a regressão linear não servir para prever probabilidade.

Exercício (Razão de chances)

$\hat{\beta}_1 = 1,1$. O que acontece com as *chances* a cada $+1$ no preditor? E se fosse $\hat{\beta}_1 = -1,1$?

Exercício (Limiar e custo)

No exemplo do crédito (FN custa caro? FP custa caro?), argumente se o banco deve usar limiar 0,3 ou 0,7 — e diga o que acontece com precisão e recall na sua escolha.

Laboratório — no seu banco de dados

Escolha (ou crie) uma resposta **binária** y (0/1) no seu banco:

```
# 1) ajustar a logistica e ler razoes de chance:
m <- glm(y ~ x1 + x2, family = binomial, data = dados)
summary(m); exp(coef(m))

# 2) prever probabilidade e classe (limiar 0.5) + matriz de confusao:
p <- predict(m, type = "response")
yhat <- as.integer(p > 0.5)
table(real = dados$y, previsto = yhat)

# 3) repita com limiar 0.3 e 0.7 e compare as matrizes

# 4) AUC:
mean(outer(p[dados$y == 1], p[dados$y == 0], ">"))
```

Observação

Entregar: o modelo, a interpretação de *uma* razão de chances em uma frase, as matrizes nos três limiares e a resposta: no seu problema, qual erro (FP ou FN) custa mais caro — e que limiar você usaria?

- **Logística:** prevê $P(Y = 1)$ via curva em S; linear no **logit**.
- **Interpretação:** e^{β_1} multiplica as **chances** a cada +1; a fronteira fica em $x^* = -\beta_0/\beta_1$ (onde $p = 0,5$).
- **Estimação:** máxima **verossimilhança** — os dados observados ficam os mais prováveis.
- **Avaliação:** limiar $\rightarrow$ matriz de confusão (precisão, recall) e **ROC/AUC** para todos os limiares.

Próxima aula: como medir o desempenho *fora da amostra*? Avaliação e seleção de modelos.

Um mapa das duas primeiras famílias

	Regressão linear	Regressão logística
Resposta Y	quantitativa (vendas)	qualitativa (paga/não paga)
Saída	valor $\hat{y}$	probabilidade p
Estimação	mínimos quadrados	máxima verossimilhança
Interpretação	β_1 soma em $\hat{y}$	e^{β_1} multiplica as chances
Avaliação	R^2 , resíduos	matriz de confusão, ROC/AUC
R	<code>lm()</code>	<code>glm(..., binomial)</code>