

Aula 2 — Dados e variáveis

Dicionário de variáveis; tipos de variáveis; e como o R guarda os dados

Prof. Dr. João Paulo Ferreira de Mello

6 de agosto de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

O que vamos ver hoje

- **De onde viemos:** na Aula 1, aprender é *estimar f* a partir de dados.
- **O novo:** antes de estimar nada, é preciso *entender os dados* — o **dicionário de variáveis**, os **tipos de variáveis** e como o R guarda cada um.
- **Para onde vai:** é a base do **trabalho da disciplina** e de toda a estatística descritiva da Aula 3.

Hoje a régua é simples: sair daqui sabendo *olhar* para uma tabela de dados.

- Vocês vão **escolher um banco de dados** e aplicar, ao longo do curso, as técnicas que aprendermos.
- O primeiro passo — e o mais negligenciado — é **entender os dados**: o que é cada variável, de que tipo é, como está guardada.

Observação

Um bom trabalho começa por um bom **dicionário de variáveis**. É por ele que começamos hoje.

Dicionário de variáveis

O ponto de partida: uma tabela de dados

id	idade	sexo	cd_uf	vl_renda	sit_cred
1	34	1	35	2500	A
2	51	2	33	4800	B
3	23	1	41	1800	A

O que é `cd_uf`? `sexo` vale 1/2 para quê? `sit_cred` A/B/C significa o quê?

Observação

Sem um **dicionário de variáveis**, cada coluna é um enigma — e a análise vira chute.

O que é um dicionário de variáveis

Definição

O **dicionário de variáveis** (*data dictionary*) é o documento que descreve cada variável do banco. Para cada uma, registra:

- **nome** (como aparece na tabela) e **descrição**;
- **tipo** (qualitativa/quantitativa — ver adiante);
- **domínio**: valores possíveis, unidade ou código;
- **observações**: como foi medida, faltantes, códigos especiais.

Observação

Muitas bases públicas (IBGE, Kaggle, gov.br) já vêm com dicionário — a primeira tarefa é lê-lo.

Exemplo: dicionário da tabela anterior

Variável	Descrição	Tipo	Valores / unidade
idade	idade do cliente, em anos	quantitativa discreta	inteiro ≥ 18
sexo	sexo informado	qualitativa nominal	1 = fem.; 2 = masc.
cd_uf	código IBGE da UF	qualitativa nominal	11 a 53
vl_renda	renda mensal declarada	quantitativa contínua	em R\$, ≥ 0
sit_cred	situação de crédito	qualitativa ordinal	$A > B > C$

Agora a tabela *fala*: sabemos ler, resumir e checar cada coluna.

Tipos de variáveis


Um pouco de estatística: a tabela organizada

- **População** é o todo que queremos entender; **amostra** é a parte que observamos.
- Na tabela *organizada*: cada **linha** é uma **observação** e cada **coluna** é uma **variável**.

Observação

É a notação da Aula 1: são n observações e p variáveis. Os preditores $X_1, \dots, X_p$ e a resposta Y são *colunas* desta tabela.



Tipos de variáveis



- **Nominal:** categorias sem ordem. **Ordinal:** categorias com ordem.
- **Discreta:** contagem (valores isolados). **Contínua:** medida (qualquer valor num intervalo).

Por que o tipo importa

O tipo decide o *resumo*, o *gráfico* e a *técnica*: barras e frequência para qualitativa; histograma e média para quantitativa.



Observação

Liga com a Aula 1: resposta quantitativa $\Rightarrow$ *regressão*; qualitativa $\Rightarrow$ *classificação*.

Como o R guarda os dados

Os tipos básicos do R

Toda variável, no R, é guardada em um **tipo**. Os quatro mais comuns:

```
c(inteiro = typeof(2L), real = typeof(2.5),  
  texto = typeof("A"), logico = typeof(TRUE))  
  
#>      inteiro      real      texto      logico  
#> "integer" "double" "character" "logical"
```

`class()` dá o *papel* da variável (ex. factor, Date); `typeof()` dá o *armazenamento*.

Do tipo da variável ao tipo no R

Variável (estatística)	Tipo no R
Qualitativa nominal	<code>factor</code>
Qualitativa ordinal	<code>factor ordenado (ordered = TRUE)</code>
Quantitativa discreta	<code>integer</code>
Quantitativa contínua	<code>double (numérico)</code>
Identificador / texto livre	<code>character</code>

Observação

Erro clássico: guardar **código** (CEP, CPF, `cd_uf`) como número. É rótulo, não quantidade — vira `character` ou `factor`, nunca entra numa média.

O R em ação: tipando um data.frame

```
d <- data.frame(
  id      = 1:3,
  sexo    = c("F", "M", "F"),
  escol   = c("medio", "superior", "fundamental"),
  renda   = c(2500, 4800.5, 1800),
  filhos  = c(0L, 2L, 1L))
sapply(d, class)      # o papel de cada coluna

#>      id      sexo      escol      renda      filhos
#> "integer" "character" "character" "numeric" "integer"
```

Observação

escol entrou como character: o R ainda não sabe que é ordinal. Vamos corrigir.

Corrigindo os tipos das qualitativas

```
d$sexo <- factor(d$sexo) # nominal
d$escol <- factor(d$escol,
                  levels = c("fundamental", "medio", "superior"),
                  ordered = TRUE) # ordinal
sapply(d, function(x) class(x)[1])

#>      id      sexo      escol      renda      filhos
#> "integer" "factor" "ordered" "numeric" "integer"
```

Observação

Agora sexo é factor e escol é ordered — prontos para resumos, gráficos e modelos.

Exercícios

Exercício

Para cada variável, dê o *tipo estatístico* (qualitativa nominal/ordinal, quantitativa discreta/contínua) e o *tipo no R*:

- | | |
|-----------------------------|---------------------------------------|
| a) temperatura (°C); | d) faixa de renda (baixa/média/alta); |
| b) estado civil; | e) CEP; |
| c) nº de acessos a um site; | f) nota de 0 a 10. |

Exercício (Dicionário)

Escolha (ou imagine) um banco com **4 variáveis** e escreva o **dicionário** delas: nome, descrição, tipo e domínio.

Exercício (Código não é número)

Explique por que guardar `cd_uf` (código da UF) como número pode induzir a erros na análise. Qual tipo do R você usaria?

Exercício (Ordinal)

Por que “faixa de renda” (baixa/média/alta) deve ser um factor *ordenado*, e não um character qualquer?

Sobre um `data.frame` (o seu, ou `iris`): inspecione, corrija os tipos e comece o dicionário.

```
str(dados)           # tipo e amostra de cada coluna
summary(dados)      # resumo coerente com o tipo
sapply(dados, class)

# 1) converter uma categorica guardada como numero em factor:
dados$cd_uf <- factor(dados$cd_uf)
# 2) tornar uma ordinal um factor ORDENADO (niveis na ordem certa)
# 3) montar o dicionario: nome | descricao | tipo | dominio
```

Observação

Tarefa: traga o dicionário do banco que você escolheu para o trabalho. Pacote: `base`.

- O **dicionário de variáveis** descreve cada coluna — é o ponto de partida do trabalho.
- Variáveis são **qualitativas** (nominal/ordinal) ou **quantitativas** (discreta/contínua).
- O **tipo** decide resumo, gráfico e técnica.
- No R: factor (nominal), factor ordenado (ordinal), integer/double, character.

Próxima aula: com os dados entendidos e tipados, vamos *explorá-los* — estatística descritiva e gráficos (EDA) no R.