

Aula 3 — Análise exploratória e variáveis aleatórias

EDA: resumir e visualizar; variáveis aleatórias; distribuições discretas e contínuas

Prof. Dr. João Paulo Ferreira de Mello

13 de agosto de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

O que vamos ver hoje

- **De onde viemos:** na Aula 2, sabemos ler e tipar as variáveis de um banco.
- **O novo (com ênfase):** **(1)** a *análise exploratória* (EDA) — resumir e visualizar; **(2)** as *variáveis aleatórias* e suas *distribuições* (discretas e contínuas), o modelo por trás dos dados.
- **Para onde vai:** EDA e distribuições sustentam todo modelo do curso — e são a próxima etapa do seu **trabalho**.

Análise exploratória (EDA)

O que é análise exploratória

Definição

Análise exploratória de dados (EDA) é olhar os dados — com *resumos* e *gráficos* — antes de modelar, para descobrir padrões, erros, a forma das distribuições e as relações entre variáveis.

Observação

É a etapa que mais evita erro no trabalho: um *outlier*, um valor impossível ou uma coluna torta aparecem aqui, não no modelo.

Resumindo uma variável quantitativa

Posição (centro):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (\text{média}), \quad \text{mediana}, \quad \text{moda}.$$

Dispersão (espalhamento):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s = \sqrt{s^2}, \quad \text{IQR} = Q_3 - Q_1.$$

Observação

A **média** é sensível a *outliers*; a **mediana** é robusta. Comparar as duas já diz muito — é o próximo slide.


Média, mediana e assimetria

Quando **média** $\neq$ **mediana**, a distribuição é **assimétrica**:

- média $>$ mediana $\Rightarrow$ cauda à **direita** (assimetria positiva);
- média $<$ mediana $\Rightarrow$ cauda à **esquerda**;
- média $\approx$ mediana $\Rightarrow$ **simétrica**.

A mediana resiste à cauda; a média é *puxada* por ela.



```
par(mar = c(4,4,1,1), pty = "s") # quadrado
x <- rgamma(2000, shape = 2, scale = 1)
hist(x, prob = TRUE, col = cfill, border = "white",
     main = "", xlab = "x", ylab = "densidade")
abline(v = mean(x), col = claranja, lwd = 3)
abline(v = median(x), col = cverde, lwd = 3, lty = 2)
legend("topright", c("media", "mediana"), bty = "n",
      col = c(claranja, cverde), lwd = 3, lty = c(1,2))
```



Visualizando uma variável

Histograma (forma) e **boxplot** (mediana, quartis, *outliers*).



```
renda <- rgamma(300, shape = 2, scale = 1500)
par(mfrow = c(1,2), mar = c(4,4,2,1), pty = "s") # dois painéis QUADRADOS
hist(renda, col = cfill, border = "white", main = "Histograma", xlab = "renda")
boxplot(renda, col = azul, main = "Boxplot", ylab = "renda")
```



Relação entre duas variáveis

Dispersão (quant. $\times$ quant.) e **boxplot por grupo** (quant. $\times$ qual.).

```
x <- runif(200, 0, 10); y <- 2 + 1.3 * x + rnorm(200, 0, 2)
g <- factor(sample(c("A", "B", "C"), 200, replace = TRUE))
par(mfrow = c(1,2), mar = c(4,4,2,1), pty = "s")
plot(x, y, pch = 19, col = "blue", main = "Dispersao")
boxplot(rnorm(200, as.integer(g)) ~ g, col = "lightblue", main = "Por grupo",
        xlab = "grupo", ylab = "valor")
```



- **Assimetria:** distribuições “puxadas” para um lado (renda, preços) — média $\neq$ mediana.
- **Outliers:** valores muito fora — erro de digitação ou caso real? O boxplot os aponta.
- **Faltantes (NA):** conte-os antes de tudo (`sum(is.na(...))`); decida como tratar.

Observação

A EDA não é enfeite: cada gráfico é uma *pergunta* aos dados.

Variáveis aleatórias

Definição

Uma **variável aleatória** (v.a.) X associa um *número* a cada resultado de um experimento aleatório.

- **Discreta:** valores isolados (contagem). Ex.: nº de caras em 3 lançamentos; nº de acessos por minuto.
- **Contínua:** qualquer valor num intervalo (medida). Ex.: altura; tempo até uma falha.

Observação

É a ponte entre os *dados* (Aula 2) e o *modelo*: o histograma da EDA é uma amostra da distribuição *teórica* de X .

A distribuição de probabilidade de X

Discreta — função de probabilidade

$$p(x) = P(X = x), \quad \sum_x p(x) = 1.$$

$$\mathbb{E}[X] = \sum_x x p(x).$$

Contínua — densidade $f(x) \geq 0$

$$P(a \leq X \leq b) = \int_a^b f(x) dx, \quad \int_{-\infty}^{\infty} f = 1.$$

$$\mathbb{E}[X] = \int x f(x) dx.$$

Em ambos, a **variância** mede o espalhamento: $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$.

Observação

Na contínua, a probabilidade é *área* sob a curva — e $P(X = x) = 0$ para um ponto isolado.

Distribuições discretas

Três distribuições discretas

Distribuição	Problema modelo (para lembrar)	$\mathbb{E}[X]$	$\text{Var}(X)$
Bernoulli(p)	<i>Este cliente compra? (1 tentativa, sim/não)</i>	p	$p(1 - p)$
Binomial(n, p)	<i>De n clientes, quantos compram?</i>	np	$np(1 - p)$
Poisson(λ)	<i>Quantas chamadas chegam por minuto?</i>	λ	λ



Observação

A chave: **Binomial** conta sucessos num nº fixo de tentativas; **Poisson** conta ocorrências num *intervalo* de tempo/espço.

Função de probabilidade: Binomial e Poisson

No R: `dbinom(k, n, p)` e `dpois(k, lambda)` dão $P(X = k)$.

```
k <- 0:12
par(mfrow = c(1,2), mar = c(4,4,2,1), pty = "s")
plot(k, dbinom(k, 12, 0.3), type = "h", lwd = 4, col = "blue",
     main = "Binomial(12, 0.3)", ylab = "P(X=k)")
plot(k, dpois(k, 3), type = "h", lwd = 4, col = "orange",
     main = "Poisson(3)", ylab = "P(X=k)")
```



Distribuições contínuas

Três distribuições contínuas

Distribuição	Problema modelo (para lembrar)	$\mathbb{E}[X]$	$\text{Var}(X)$
Uniforme(a, b)	Sortear um instante entre a e b (todos iguais)	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Normal(μ, σ^2)	Altura de adultos; erro de medição	μ	σ^2
Exponencial(λ)	Tempo até a próxima falha/chamada	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$



Observação

A **Normal** (soma de muitos efeitos pequenos) é simétrica: cerca de **68–95–99,7%** dos valores caem a 1–2–3 desvios de μ .

Densidade: Normal e Exponencial

No R: `dnorm`, `dexp` (densidade); `rnorm`, `rexp` (simular).


```
par(mfrow = c(1,2), mar = c(4,4,2,1), pty = "s")
curve(dnorm(x), -4, 4, lwd = 3, col = "blue", main = "Normal(0, 1)",
      ylab = "densidade")
curve(dexp(x, 1), 0, 6, lwd = 3, col = "orange", main = "Exponencial(1)",
      ylab = "densidade")
```



Do histograma à densidade

Aqui a EDA encontra a teoria: o **histograma** dos dados aproxima a **densidade** da v.a. que os gerou.

```
par(mar = c(4,4,1,1), pty = "s")
d <- rnorm(500, mean = 170, sd = 8)
hist(d, prob = TRUE, col = cfill, border = "white",
     main = "", xlab = "altura (cm)")
curve(dnorm(x, 170, 8), add = TRUE,
      lwd = 3, col = claranja)
```



Exercícios e trabalho

Exercício

Para os dados $\{4, 8, 8, 10, 20\}$, calcule **média**, **mediana** e **desvio-padrão** amostral. Média e mediana concordam? O que isso sugere?

Exercício

Uma v.a. discreta tem $p(0) = 0,5$, $p(1) = 0,3$, $p(2) = 0,2$. Calcule $\mathbb{E}[X]$ e $\text{Var}(X)$.

Exercício

$X \sim \text{Poisson}(\lambda = 2)$ é o nº de chamadas por minuto. Escreva, no R, como obter $P(X = 0)$ e $P(X \geq 3)$.

Exercício (Qual distribuição?)

Para cada situação, diga qual *problema modelo* ela lembra e qual distribuição usar: (a) nº de peças defeituosas em um lote de 100; (b) tempo até o próximo cliente entrar na loja; (c) um resultado de cara ou coroa.

Exercício (Discreta ou contínua?)

Classifique: nº de filhos; tempo de espera; nº de e-mails/dia; temperatura.

Exercício (Lendo um boxplot)

O que a caixa, a linha central e os pontos além dos “bigodes” representam?

Laboratório — no seu banco de dados

Aplique ao banco que você escolheu para o **trabalho**:

```
# 1) EDA de uma variável QUANTITATIVA do seu banco:  
summary(dados$var); sd(dados$var, na.rm = TRUE)  
hist(dados$var, prob = TRUE); boxplot(dados$var) # use par(pty="s")  
  
# 2) relação entre DUAS variáveis (scatter ou boxplot por grupo):  
plot(dados$x, dados$y); boxplot(dados$y ~ dados$grupo)  
  
# 3) escolha UMA variável contínua e sobreponha uma densidade Normal:  
curve(dnorm(x, mean(dados$var), sd(dados$var)), add = TRUE)  
  
# 4) conte os faltantes de cada coluna:  
colSums(is.na(dados))
```

Observação

Entregar: 2 gráficos *quadrados* e comentados do seu banco + uma frase sobre a *forma* da distribuição de uma variável (simétrica? assimétrica? qual distribuição lembra?).

- **EDA:** resumir (posição, dispersão) e visualizar antes de modelar; **média** $\neq$ **mediana** sinaliza assimetria.
- **Variável aleatória:** associa números a resultados; **discreta** ou **contínua**.
- **Distribuição:** $p(x)$ ou densidade $f(x)$; resumida por $\mathbb{E}[X]$ e $\text{Var}(X)$.
- Cada distribuição tem um **problema modelo:** Bernoulli/Binomial/Poisson; Uniforme/Normal/Exponencial.

Próxima aula: o primeiro modelo supervisionado — *regressão linear*.