

## Aula 4 — Regressão linear

Mínimos quadrados; avaliação ( $R^2$ ); regressão múltipla; diagnóstico

---

Prof. Dr. João Paulo Ferreira de Mello

21 de agosto de 2026

Ciências de Dados

Fatec Rubens Lara – Baixada Santista

# O que vamos ver hoje

- **De onde viemos:** já sabemos explorar dados e pensar em distribuições (Aula 3).
- **O novo:** o **primeiro modelo supervisionado** — a *regressão linear* — que estima  $f$  supondo que ela é uma **reta** (ou um plano).
- **Para onde vai:** é a base para avaliação de modelos, regularização e para a classificação (próxima aula).

## Observação

Aqui a resposta  $Y$  é **quantitativa** — portanto, um problema de *regressão* (Aula 1).


# Regressão linear simples

---

# Existe uma reta que resume a relação?

Nos dados de publicidade, mais verba de TV tende a mais vendas. Queremos a **reta** que melhor descreve essa relação — para *prever* e para *interpretar*.

```
par(mar = c(4,4,1,1), pty = "s") # quadrado
plot(tv, vendas, pch = 19, col = "azul",
     xlab = "verba de TV", ylab = "vendas")
abline(lm(vendas ~ tv), col = "laranja", lwd = 3)
```



# O modelo linear simples

## Definição

$$Y = \beta_0 + \beta_1 X + \varepsilon, \quad \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

- $\beta_0$  (**intercepto**): valor médio de  $Y$  quando  $X = 0$ .
- $\beta_1$  (**inclinação**): quanto  $Y$  varia, em média, a cada +1 **unidade** de  $X$ .
- $\varepsilon$ : o erro — tudo o que a reta não captura.

## Observação

“Linear” é nos *parâmetros*  $\beta$ . O objetivo é estimar  $\hat{\beta}_0, \hat{\beta}_1$  a partir dos dados.


# Mínimos quadrados

Escolhemos  $\hat{\beta}_0, \hat{\beta}_1$  que **minimizam** a soma dos quadrados dos *resíduos*  $e_i = y_i - \hat{y}_i$ :

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

Cada segmento verde é um *resíduo*; a reta é a que deixa a soma dos *quadrados* deles a menor possível.

```
i <- 1:15 # subconjunto p/ enxergar
m0 <- lm(vendas[i] ~ tv[i])
par(mar = c(4,4,1,1), pty = "s")
plot(tv[i], vendas[i], pch = 19, col = "blue",
     xlab = "TV", ylab = "vendas")
abline(m0, col = "orange", lwd = 3)
segments(tv[i], vendas[i],
         tv[i], fitted(m0), col = "green", lwd = 2)
```



# O ajuste no R: `lm()`

Uma linha ajusta o modelo; `coef` dá os  $\hat{\beta}$  e `summary` o resto.

```
m <- lm(vendas ~ tv)      # vendas explicada por TV
coef(m)                   # (Intercept) = b0 ; tv = b1

#> (Intercept)          tv
#>      8.43507      0.03512
```

Interpretação: a cada +1 de verba de TV, as vendas sobem, em média,  $\hat{\beta}_1$ .

## Observação

`predict(m, data.frame(tv = 50))` prevê as vendas para uma verba de 50.

## Avaliando o ajuste

---

## Quão bom é o ajuste? $R^2$

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}, \quad \text{TSS} = \sum_i (y_i - \bar{y})^2.$$

- $R^2 \in [0, 1]$ : **fração da variância de  $Y$  explicada** pelo modelo.
- Perto de 1: a reta explica bem; perto de 0: quase não explica.
- $\text{RSE} = \sqrt{\text{RSS}/(n-2)}$ : erro típico, na unidade de  $Y$ .

```
summary(m)$r.squared      # R2 do modelo vendas ~ tv
```


```
#> [1] 0.08563
```

# Diagnóstico: o gráfico de resíduos

Resíduo contra valor *ajustado*. O que se quer ver: uma **nuvem sem padrão** em torno de zero.

- *curva*  $\Rightarrow$  relação não é linear;
- *funil*  $\Rightarrow$  variância não constante;
- *pontos isolados*  $\Rightarrow$  outliers.

```
par(mar = c(4,4,1,1), pty = "s")  
plot(fitted(m), resid(m), pch = 19, col = "blue",  
     xlab = "ajustado", ylab = "residuo")  
abline(h = 0, col = "orange", lwd = 3, lty = 2)
```



# Regressão múltipla

---

## Definição

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon.$$

- Cada  $\hat{\beta}_j$  é o efeito de  $X_j$  **mantendo os demais preditores fixos**.
- Um preditor pode “perder” significância ao lado de outro correlacionado com ele.

## Observação

É a mesma ideia da reta, agora um *plano* (ou hiperplano). O  $\mathcal{L}_m(\ )$  muda só do lado direito da fórmula.

# Regressão múltipla no R

Basta somar preditores na fórmula:

```
m2 <- lm(vendas ~ tv + radio)
round(summary(m2)$coefficients[, c(1, 4)], 4)  # estimativa e p-valor
```

| #>             | Estimate | Pr(> t ) |
|----------------|----------|----------|
| #> (Intercept) | 3.1205   | 0        |
| #> tv          | 0.0425   | 0        |
| #> radio       | 0.1906   | 0        |

```
round(summary(m2)$r.squared, 4)  # R2
```

```
#> [1] 0.6897
```

## Observação

O **p-valor** testa  $\beta_j = 0$ : pequeno ( $< 0,05$ ) sugere que o preditor contribui.  $R^2$  subiu ao acrescentar radio.

## Quatro cuidados

- **Linearidade:** confira no gráfico de resíduos (frame anterior).
- **Outliers e alavancagem:** um ponto extremo pode dominar a reta.
- **Multicolinearidade:** preditores muito correlacionados tornam os  $\hat{\beta}$  instáveis.
- **Correlação  $\neq$  causalidade:** o modelo mede associação, não prova causa.

### Observação

$R^2$  alto não valida o modelo sozinho — sempre olhe os resíduos.

## **Exercícios e trabalho**

---

### Exercício

Um modelo estimou  $\hat{y} = 3 + 0,05x$  (vendas em mil,  $x$  = verba de TV). Preveja as vendas para  $x = 40$  e interprete a inclinação 0,05.

### Exercício

Um ajuste tem  $RSS = 120$  e  $TSS = 400$ . Calcule o  $R^2$  e diga que fração da variância ficou *sem* explicação.

### Exercício

Em vendas  $tv + radio$ ,  $\hat{\beta}_{radio} = 0,19$ . Escreva, em uma frase, o que esse número significa.

## Exercício (Resíduos)

Por que minimizamos a soma dos *quadrados* dos resíduos, e não a soma simples deles?

## Exercício (Diagnóstico)

Você vê um “funil” no gráfico de resíduos (espalhamento cresce com o ajustado). Que suposição foi violada?

## Exercício ( $R^2$ )

Dois modelos têm  $R^2 = 0,9$ , mas um tem resíduos com forte padrão de curva. Qual você confia mais e por quê?

# Laboratório — no seu banco de dados

Escolha uma resposta **quantitativa** e um ou mais preditores do seu banco:

```
# 1) regressao simples + interpretacao do coeficiente:
m <- lm(y ~ x1, data = dados)
summary(m)                                # b0, b1, p-valor, R2

# 2) grafico QUADRADO com a reta ajustada:
par(pty = "s"); plot(dados$x1, dados$y); abline(m, col = "orange", lwd = 3)

# 3) regressao multipla (some preditores) e compare o R2:
m2 <- lm(y ~ x1 + x2, data = dados)

# 4) diagnostico: residuos vs ajustado (par(pty="s"))
plot(fitted(m2), resid(m2)); abline(h = 0)
```

## Observação

**Entregar:** o modelo, a interpretação de um coeficiente, o  $R^2$  e o gráfico de resíduos (quadrado) com um comentário.

- **Regressão linear:**  $Y = \beta_0 + \beta_1 X_1 + \dots + \varepsilon$ ; estima  $f$  como reta/plano.
- **Mínimos quadrados:** os  $\hat{\beta}$  minimizam a soma dos quadrados dos resíduos.
- **Avaliação:**  $R^2$  (variância explicada) e o gráfico de resíduos.
- **Múltipla:** cada  $\hat{\beta}_j$  é o efeito de  $X_j$  com os demais fixos.

**Próxima aula:** e quando a resposta é *qualitativa*? Classificação e *regressão logística*.